

ENTREGA FINAL

Caso: Clínica de salud. Un paciente escribe por Whatsapp o completa un formulario web. El sistema clasifica la intención y la urgencia del mensaje, busca el protocolo clínico correspondiente en una base de datos propia, redacta una respuesta y la deja detenida hasta que un profesional de la clínica la apruebe. Solo entonces se envía al paciente. Los mensajes de alta urgencia se derivan directo a un humano por Slack, sin pasar por la redacción automática.

Cuadro Comparativo de la Optimización de Costos:

Para clasificar la intención y la urgencia del mensaje.

Modelo	Input/output por MTok	Características
Claude Haiku 4.5	US\$ 1 / US\$ 5	Tarea simple de clasificación con salida corta (JSON de una línea). No necesita razonamiento profundo; Haiku es el más barato y el más rápido, ideal para no sumar latencia antes del router de urgencia. Es rápido, barato, y de la misma familia que Sonnet (mismo formato de API, mismo nodo en n8n).
GPT-5 mini	US\$ 0,25 / US\$ 2	Cuesta 0,25 por millón de tokens de entrada y 2 dólares por millón de salida. Más barato que Haiku en este tramo.
Gemini 2.5/3.5 Flash-Lite	US\$ 0,10 / US\$ 0,40	Cuesta 0,10 dólares por millón de tokens de entrada y 0,40 por millón de salida en el nivel pago. El más barato de los cuatro para esta tarea.
Llama 4 Scout	≈ US\$ 0,08–0,10 / US\$ 0,30	Meta no vende una API propia de Llama — hay que elegir un host de terceros como Together AI, Fireworks, Groq o Deepinfra. Vía esos hosts,

		Llama 4 Scout cuesta cerca de 0,08 dólares por millón de tokens de entrada y 0,30 por millón de salida.
--	--	---

Para redactar la respuesta usando una RAG:

Modelo	Input/output por MTok	Características
Claude Sonnet 5	US\$ 2 / US\$ 10	El elegido en el proyecto por su buen manejo de instrucciones estrictas ("usa solo el contexto, no inventes"). Tarea de lectura densa: debe combinar el mensaje del paciente con varios fragmentos de protocolo del RAG sin mezclar indicaciones ni inventar datos. Requiere más capacidad de razonamiento que Haiku, sin llegar a necesitar Opus.
GPT-5	US\$ 1,25 / US\$ 10	Cuesta 1,25 dólares por millón de tokens de entrada y 10 dólares por millón de salida. Input más barato que Sonnet, output igual.
Gemini 3.1 Pro	US\$ 2 / US\$ 12 (hasta 200K de contexto)	La API de Gemini cuesta 2 dólares de entrada y 12 de salida por millón de tokens para Gemini 3.1 Pro en contextos de hasta 200 mil tokens.
Llama 4 Maverick	≈ US\$ 0,27 / US\$ 0,85	Vía Together AI u otro host — mucho más barato, pero sin el mismo historial de seguimiento fino de instrucciones en tareas de RAG delicadas.

